

1 Prioritäten

1. Zuverlässiges, robustes und reproduzierbares Vorgehen zur Extraktion und Migration der notwendigen Informationen.
2. Inkrementelles Erweitern des Outputs der Felder um sich vorläufigem Ziel-Schema anzunähern. Grundlage hierfür eine zukunftsfähige und wartbare Lösung für kommerziellen Gebrauch.
3. Erarbeiten besonderer Herausforderungen der Datenkonsolidierung (z.B. fehlende Informationen, Inkonsistenzen, Abweichungen zwischen Standorten).
4. Transparente Dokumentation der Entscheidungen und Vorgehensweise, um die Nachvollziehbarkeit zu gewährleisten. Auflistung weiterer Potenziale und aktueller Leistungen.

2 Vorgehen: Ziel 1

2.1 Exploration

- (I) Prüfen der Intra-Standort Variabilität der Eingaben (i.e. wie hoch ist die Eingabekonsistenz innerhalb der Standorte)
- (I) Prüfen der Inter-Standort Variabilität der Eingaben (i.e. wie hoch ist die Eingabekonsistenz zwischen den Standorten)
- Ziel: Gibt es Gemeinsamkeiten zwischen den Standorten die die eine einheitliche Extraktion von Informationen zulassen (required)?
- Ziel: Welche Abweichungen erschweren die Extraktion von Informationen?
- Ergebnis: Folgende Tabelle zeigt welche Informationen einheitlich aus allen Dateien zuverlässig ausgelesen werden können:

.html Quelle	Info
Titel (<h1> Tag)	Zimmer, Vermarktungsart, Objekttyp
<div class=„expose“ data-objekt-nr=„xxxx“>	Objekt-ID
Objekt-Pfad	Quelle
<p class=„lage“>„xxxx“</p>	Adresse
<table class=„eckdaten“>	Wohnflaeche

2.2 Umsetzung der Erkenntnisse

- Regex und Wortsuche aus auf <h1> als Primärquelle mit Fallback auf Eckdaten Tabelle. Warnungen und Errors werden geloggt und gesammelt mit einer Fehlerbeschreibung.
- Aufgrund von nicht eindeutig lösbaren Inkonsistenzen erwarten die fehlerhaften Outputs einen HITL Ansatz.

3 Nutzung KI

- Error handling
- jsonschema validation

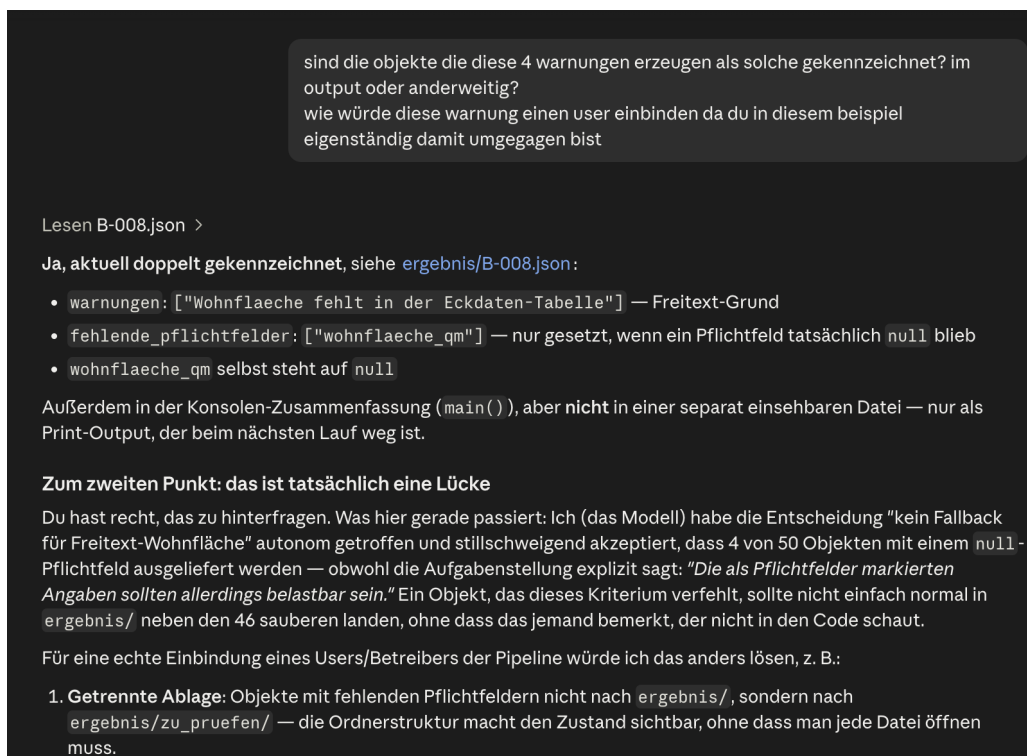


Abbildung 1: Error-Handling

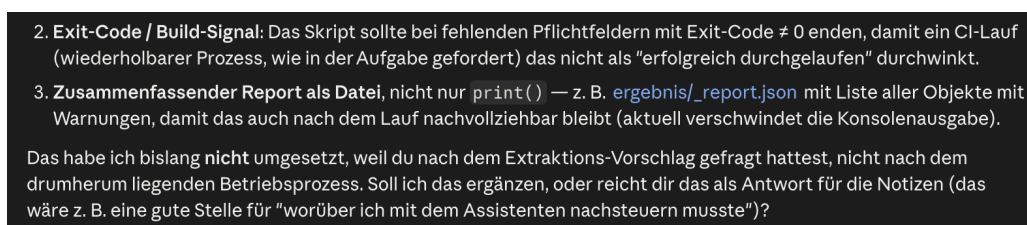


Abbildung 2: Error-Handling: Fortführung